

AgriGen AI — kernel-basiertes Sorten-Matching auf offiziellen Sortendaten

Die Sortenwahl wird zur Risiko-Entscheidung: Dürre, Krankheitsdruck, verkürzte Vegetationsperioden verlangen die Sorte, die zum konkreten Anbau-Profil passt. Offizielle Beschreibungen existieren — die **Beschreibende Sortenliste** des Bundessortenamts mit Noten 1–9 für alle zugelassenen Sorten. Aber sie sind Tabellen, keine Empfehlung: keine Anfrage, kein Ranking, kein Vergleich über Fruchtarten hinweg. AgriGen macht diese Daten matchbar.

Das Problem im Detail

Bundessortenamt & Genbanken beschreiben Sorten und Accessionen mit präzisen Noten (Resistenzen, Reife, Standfestigkeit, Ertrag, Morphologie). Die Frage eines Landwirts oder Beraters — „Welche Sorte verträgt hohen Septoria- und Fusarium-Druck, reift früh, bleibt standfest und erträgt stark?“ — beantwortet kein System: Die Daten liegen in fruchtart-spezifischen Tabellen mit unterschiedlichen Merkmalssätzen und Lücken, nicht in durchsuchbarer Form. EURISCO erschließt über 2 Millionen Genbank-Accessionen — noch stärker auf Passportdaten beschränkt.

Genau diese Struktur — heterogene Merkmalssätze, fehlende Bewertungen, fruchtart-übergreifende Anfragen — ist der Arbeitspunkt unseres Kernels.

Wer es braucht

Landwirte & Beratung bei Sortenwahl unter Klimastress;
Saatgut-Handel als Beratungswerkzeug; Züchter als Parental-Screening über Fruchtarten.

Warum jetzt

Offizielle Daten sind digital und öffentlich (BSL 2026);
Klimaanpassung ist priorisiert;
Kernel-Methoden sind in der quantitativen Genetik ausgereift — aber nie für Endanwender-Empfehlung produktisiert.

Warum wir

Engine, Evaluierung und echte Datenintegration entstehen im eigenen Code — inklusive adversarialer mathematischer Begutachtung und CI-Qualitätsgates.

Marktlage (Analyse 05/2026)

Anbieter	Ausrichtung	Abgrenzung
Heritable Agriculture (Google-X)	Genom-Plattform, Zucht	Alle treiben die Züchtung an (B2B-Genomik). Keiner beantwortet die Auswahlfrage des Endanwenders auf offiziellen Sortendaten. Diese Lücke schließt AgriGen — mit derselben mathematischen Klasse, aber als Empfehlungssystem.
Avalo (11 Mio. \$ Series A)	Climate-Crops-Zucht	
Computomics (Tübingen)	Enterprise-Genomik	
NoMaze (München)	Genomic Prediction	

Ein Rechenkern, zwei getrennte mathematische Objekte — gebaut für echte Datenlücken

Offizielle Noten

BSL Getreide 2026: Noten 1–9 je Sorte und Merkmal, normalisiert auf [0,1]. Union-Space aus 66 Deskriptoren über 13 Fruchtarten; nicht beobachtete Merkmale bleiben maskiert.



RBF-Katalog-Kern

$K(x,y) = \exp(-\gamma \cdot d^2(x,y))$ mit Median-Heuristik für γ ; bei fester Merkmalsmaske positiv definit — ein echter RKHS.



Anfrage-Scoring

Einseitige Hinge-Terme (Satisficing) mit Toleranzband: Unter-/Überschreiten des Anforderungsziels zählt, Übererfüllen ist frei; Anfragen sind Bereiche.



Ranking

Score primär; bei Gleichstand RBF-Profilähnlichkeit. Rang, dimensionsloser Score, Perzentil — Null-Überlappung ist kein Match.

$K(x,y) = \exp(-\gamma \cdot \|x-y\|^2/d) \cdot \text{feste Maske} \Rightarrow \text{PSD} \Rightarrow \text{RKHS} \cdot \text{Kernelwert} = \text{RKHS-Kosinus der Einbettungen (Einheitsdiagonale } K(z,z)=1)$

Mathematische Redlichkeit — am echten Datenmaterial gehärtet

- **Fehlende Daten sind Masken, nie Schätzungen:** nur gemeinsam beobachtete Merkmale fließen in die Distanz ein. Der Echtbetrieb mit BSL-Lücken hat zwei Schwächen aufgedeckt, die im Voll-Daten-Betrieb unsichtbar waren — beide gefixt und per Test gepinnt: **Null-Überlappung ist kein Match** (statt neutral perfekter Übereinstimmung) und ein Mindest-Abdeckungs-Gate für sinnvoll matchbare Sorten.
- **Katalog-Kern und Anfrage-Scoring sind getrennt:** der RBF-Kernel (symmetrisch, positiv definit) trägt die RKHS-Interpretation; das Anfrage-Scoring ist asymmetrisch (Satisficing) und wird ausdrücklich nicht als Kernel deklariert.
- **PSD ist bewiesen und bewacht:** Guard gegen paarweise verschiedene Scoring-Masken; ein dokumentiertes Gegenbeispiel ($\min-\lambda = -1$) ist als Test gepinnt.
- **Inspiziert von RKHS-Regression** in der quantitativen Genetik (Gianola / de los Campos) — wir produktisieren denselben Formalismus für die Empfehlungsrichtung.

Referenz-Implementierung (TypeScript)

Kern portiert aus einem produktiven Matching-System (Quelle per Commit gepinnt, semantisch diff-identisch). Drei Kernel-Räume auf echten Daten: Trait-RBF (BSL-Noten), Pedigree-Kinship (offizielle Genesys-Abstammungen) und Text-Kernel (226 amtliche CPVO-Sortenbeschreibungen, bge-m3-Embeddings, self-hosted auf eigenem Server). Läuft ohne Abhängigkeiten auf Node ≥ 22.18 — jede Aussage im Repo in fünf Minuten verifizierbar.

Engineering-Qualität

Zweiter SOLID-Rebuild in Python; CI prüft bei jedem Push: 74 Selbsttest-Checks (inkl. gepinnter Echtdaten-Deckel), Demo-Läufe und ein **Eval-Gate mit 10 Qualitäts-Deckeln** — Qualitätsregression bricht den Build. Die RRF-Fusion aus Trait- und Text-Kernel ist bewiesen identitätserhaltend.

Nachvollziehbare Empfehlung aus offiziellen Daten — statt Blackbox oder Tabellen-Sichtung

AgriGen beantwortet die Anbauprofil-Frage direkt auf der Beschreibenden Sortenliste: eine Shortlist, die jeder Fachkraft erklärbar bleibt — welcher Anforderung jede Sorte wie gut nachkommt, wo sie im Katalog-Perzentil steht, welche Kandidaten praktisch gleichwertig sind. Und erstmals fruchtart-übergreifend: Weizen, Gerste, Roggen, Dinkel, Hafer, Raps, Mais, Sojabohne, Ackerbohne, Zuckerrübe, Senf, Lein und Lupine in einer Anfrage — die Standard-Anfrage bringt derzeit vier Fruchtarten in die Top 6.

Für die Praxis

- **Landwirte & Beratung:** Anbau-Profil in natürlichen Begriffen („Septoria- und Fusarium-Druck hoch, standfest, früh, ertragsstark“) → qualifizierte Shortlist mit Erfüllungsgrad und Perzentil — direkt aus amtlichen Noten.
- **Saatgut-Handel:** Beratungsqualität ohne Sortenbuch-Blättern; pathogen-spezifische Differenzierung, die aggregierte Beschreibungen nicht hergeben.
- **Züchtung:** Parental-Screening über Trait-Profile und Fruchtarten hinweg.

Für die Datenlage

- Der maskierte Kernel ist **im Echtbetrieb auf echte Lücken getestet:** fruchtart-spezifische Merkmalsätze, teilweise bewertete Sorten, Null-Überlappungs-Fälle — alles mit definierter Semantik behandelt.
- **Äquivalenzklassen-Transparenz:** Sorten mit identischer amtlicher Beschreibung werden als solche ausgewiesen — der Matcher offenbart die Grenze der Daten statt sie zu überspielen.
- Anfragen mit wenigen Kriterien bleiben korrekt (Teilraum- γ) — keine Schätzungen aus Unbekanntem.

KI-Ehrlichkeit als Merkmal

Alle Qualitätswerte entstehen aus reproduzierbaren, label-freien Evaluierungen und sind im Repository nachvollziehbar. Grenzen werden dokumentiert, nicht verschwiegen: informationell ununterscheidbare Sorten (identische Beschreibungen), der eine dokumentierte fruchtart-übergreifende Doppelschreibung, und die quantisierte Anfrage-Genauigkeit (Stufen-Anfragen 0.59 → kontinuierlich 1.00).

452

offizielle BSL-2026-Sorten
in der laufenden Demo

13

Fruchtarten in einem
Anfrage-Raum (66 Deskriptoren)

46

eval-getriebene Iterationen,
jede mit Keep/Revert-Entscheidung

Laufende Engine auf echten Bundessortenamt-Daten, gemessene Genauigkeit

AgriGen Matcher – Union-Space: 13 Fruchtarten, echte BSL-2026-Daten

452 Sorten gesamt über 13 Fruchtarten · 66 Union-Deskriptoren
Weizen 116 · Gerste 98 · Roggen 23 · Dinkel 19 · Hafer 17
Raps 39 · Mais 60 · Zuckerrübe 38 · Soja 16 · Lupine 14 ...
Identity-Retrieval je Fruchtart (maskiert):
Weizen/Gerste/Roggen/Dinkel top-1 1.0000
Hafer 0.9412 · Mais 0.8333 · Raps 0.8205 · Sojabohne 0.6154
(jede Abweichung = ausgewiesene Äquivalenzklassen identischer BSL-Profile)
ANFRAGE (cross-crop): mehltauarm, standfest, früh, ertragsstark

Rang	Sorte	Frucht	Score
1	Glycine max 'Sussex'	Sojabohne	0.999
2	Glycine max 'Merlin'	Sojabohne	0.999
3	Triticum aestivum 'KWS Mintum'	Weizen	0.999
4	Zea mays 'Glutexo'	Mais	0.998
5	Triticum aestivum 'Campesino'	Weizen	0.998
6	Hordeum vulgare 'KWS Delis'	Gerste	0.998

Echter Demo-Lauf (node mvp/bsa-demo.ts) auf amtlichen BSL-2026-Noten: vier Fruchtarten in den Top 6

Gemessene Qualität (label-freie Evaluierung, reproduzierbar im Repo)

Kriterium	Messung
Identity-Retrieval (Anfrage = Sortenprofil)	452 amtliche Sorten, 13 Fruchtarten
Leave-One-Out-Stabilität	270 + 8.100 Entfernungen
Cross-Crop-Matching	gemeinsamer Subspace, 13 Fruchtarten
Text-Kernel (CPV0-Beschreibungen, bge-m3)	226 amtliche Sortentexte
RRF-Fusion (Traits + Text)	amtliches Ground-Truth-Label
Bedauerns-Rate bei Anfrage-Rauschen (Modellkatalog)	±0.01 / ±0.02 / ±0.05
Wizard-Genauigkeit (Stufen-Anfragen, Modellkatalog)	Vollmaske / 4 Merkmale
Skalierung	Ranking / γ-Kalibration (n=5.000)
Build-Absicherung	CI bei jedem Push

Technical Founder, der die Engine selbst baut und prüfen lässt

Sonny — Gründer & Entwickler

Baut die Matching-Engine eigenständig: Kernel-Mathematik, Datenpipeline von der amtlichen PDF-Tabelle bis zum gepinnten Deckel, Evaluierungs-Harness und Infrastruktur. Hintergrund in vektorbasierter Suche und produktionsreifen Empfehlungssystemen — der produktive Kernel-Kern von AgriGen ist ein Port aus einem live betriebenen Matching-System.

Arbeitsweise: eval-getrieben, adversarial geprüft, daten-erprobt

- 46 Iterationen mit messbaren Hypothesen, jede Entscheidung im öffentlichen Iterations-Log begründet — inklusive dreier Kernel-Räume (Traits, Abstammung, Text) auf echten Daten.
- Die Mathematik wurde von einem unabhängigen RKHS-Gutachten adversarial geprüft (inkl. vollständiger numerischer Replikation); alle Befunde eingearbeitet — inklusive eines Kernel-Fehlers, den erst echte Bundessortenamt-Lücken sichtbar machten und der mit Test gepinnt ist.
- Qualität ist automatisiert: CI prüft 74 Selbsttest-Checks (mit gepinnten Echtdaten-Deckeln), Demo-Läufe und ein Eval-Gate mit zehn Qualitäts-Deckeln.

Adaptive AI Solutions

Einreichende Arbeitsplattform des Gründers für KI-Produktarbeit im Ruhrgebiet; Produktmarke für diese Einreichung: **AgriGen AI**.

Passung zum BRYCK-Umfeld

Pre-Seed-Phase, technische Umsetzungsstärke als Kernkompetenz; gesucht: Zugang zu Mentoring und Pilotkunden-Netzwerk (Beratung, Saatgut-Handel, Zucht).

Von 452 amtlichen Sorten in 13 Fruchtarten zur vollständigen offiziellen Sortenlandschaft

Roadmap

Phase	Inhalt	Zeitfenster
M2a — BSL ausbauen	Das komplette Getreide-Heft 2026 lebt bereits: 13 Fruchtarten, 452 Sorten. Rest: Sommerraps, Silomais und die Kartoffel-Heftreihe nach demselben doppelt verifizierten Parser-Prozess — ohne neue Mechanik.	läuft seit 08/2026
M2b — Datenraum erweitern	Erste Etappe läuft: offizielle Genesys-Abstammungen (Pedigree-Kernel) und 226 CPVO-Sortenbeschreibungen (Text-Kernel, bge-m3, self-hosted) sind integriert. Weiter: EURISCO-Passportdaten und C&E-Harmonisierung.	läuft / 2027
M3 — API & Web-Demo	FastAPI-Wrapper um den Rechenkern; Match-Wizard als Web-Oberfläche (Anfrage-Präzision nach der gemessenen Quantisierungs-Leiter: kontinuierliche Regler = 1.000).	Q4 2026
M4 — Pilotkunden	Beratungsgesellschaften und Saatgut-Handel im Ruhrgebiet/NRW; Feedback-Schleife in die Merkmals-Harmonisierung.	2027

Skalierungspfad der Engine (gemessen, nicht behauptet)

- **Ranking skaliert linear** ($O(n \cdot d)$): ~5 ms bei 5.000 Sorten — für die gesamte BSL-Sortenlandschaft ohne Architekturwechsel.
- **γ-Kalibration über Stichprobe** statt aller Paare: konstant ≈ 100 ms unabhängig von n , Ranking nachweislich unverändert.
- **Datenpipeline als Reproduzierbarkeits-Vertrag:** committede Parser, dokumentierte Spaltenverifikation, Coverage-Gates, Äquivalenzklassen-Ausweisung — jeder neue BSL-Band läuft mit demselben Qualitätsschutz durch.
- **Two-Stage-Retrieval** (grober Kandidaten-Filter → exaktes Re-Ranking) ist bei Millionen-Accessionen der dokumentierte nächste Schritt — die HNSW-Erfahrung existiert in der Produktivumgebung, aus der der Kern portiert wurde.

Warum das jetzt trägt

Der Rechenkern steht auf messbarer Decke jedes falsifizierbaren Kriteriums — auf offiziellen Daten, mit bewiesener Stabilität unter Katalogveränderung und Robustheit gegen Anfrage-Ungenauigkeit. Das Risiko des Projekts ist nicht die Mathematik und nicht der Datenzugang, sondern nur noch Produktarbeit: Wizard, API, Piloten. Genau diese Arbeit ist für einen Technical Founder ohne Agentur-Abhängigkeit umsetzbar.