

AgriGen AI — kernel-basiertes Sorten-Matching für klimaresiliente Landwirtschaft

Die Sortenwahl wird zur Risiko-Entscheidung: Dürre, Hitze, verkürzte Vegetationsperioden und versalzende Böden verlangen nach Accessionen, die zu einem konkreten Anbau-Profil passen. Genbanken katalogisieren Millionen solcher Accessionen — aber ihre Suche filtert Passportfelder, sie empfiehlt nicht.

Das Problem im Detail

EURISCO, der europäische Suchkatalog für pflanzengenetische Ressourcen, erschließt über **2 Millionen Accessionen** aus 400 Instituten. Die Suche erschöpft sich in taxonomischen und herkunftsbezogenen Filtern. Die Frage eines Landwirts oder Beraters — „*Welche Accession verträgt extreme Dürre, hohe Hitze, kommt mit 350 mm Wasser aus und toleriert mäßige Salinität?*“ — beantwortet kein System.

Quantitative Eigenschaftsdaten (Toleranzen, Ertrag, Wasserbedarf) liegen in Characterization-& Evaluation-Daten vor — heterogen, lückenhaft, ohne harmonisierte Vergleichsskala. Genau dort setzt AgriGen an.

Wer es braucht

Landwirte & Beratung bei Sortenwahl unter Klimastress; Genbank-Kuratoren für Zugangswertigkeit; Züchter als Parental-Screening.

Warum jetzt

Klimaanpassung ist finanziert und politisch priorisiert; Kernel-Methoden sind in der quantitativen Genetik ausgereift — aber nie für Endanwender-Empfehlung produktisiert.

Warum wir

Engine und Evaluierung entstehen im eigenen Code — inklusive adversarialer mathematischer Begutachtung und CI-Qualitätsgates.

Marktlage (Analyse 05/2026)

Anbieter	Ausrichtung	Abgrenzung
Heritable Agriculture (Google-X)	Genom-Plattform, Zucht	Alle treiben die Züchtung an (B2B-Genomik). Keiner beantwortet die Auswahlfrage des Endanwenders : welche existierende Accession passt zu meinem Anbau-Profil. Genau diese Lücke schließt AgriGen — mit derselben mathematischen Klasse, aber als Empfehlungssystem.
Avalo (11 Mio. \$ Series A)	Climate-Crops-Zucht	
Computomics (Tübingen)	Enterprise-Genomik	
NoMaze (München)	Genomic Prediction	
Rainbow Crops (9,7 Mio. € Seed)	Zucht-Beschleunigung	

Ein Rechenkern, zwei sauber getrennte mathematische Objekte

Trait-Vektoren

12 Merkmale je Accession
— Toleranzen, Resistenz,
pH-Fenster, Vegetation,
Ertrag, Wasser, Wurzel —
normalisiert auf [0,1];
Ertrag pro
Fruchtartgruppe.



RBF-Katalog-Kern

$K(x,y)=\exp(-\gamma \cdot d^2(x,y))$
mit Median-Heuristik für
 γ ; bei fester
Merkmalsmaske positiv
definit — ein echter
RKHS.



Anfrage-Scoring

Einseitige Hinge-Terme
(Satisficing): Unter-/
Überschreiten des
Anforderungsziels zählt,
Übererfüllen ist frei.
Anfragen sind Bereiche
($\pm \frac{1}{2}$ Wizard-Stufe).



Ranking

Score primär; bei
Gleichstand entscheidet
die RBF-Profilähnlichkeit.
Ausgabe: Rang,
dimensionsloser Score,
Perzentil.

$K(x,y) = \exp(-\gamma \cdot \|x-y\|^2/d) \cdot \text{feste Maske} \Rightarrow \text{PSD} \Rightarrow \text{RKHS} \cdot \text{Kernelwert} = \text{RKHS-Kosinus}$
der Einbettungen (Einheitsdiagonale $K(z,z)=1$)

Mathematische Redlichkeit als Designprinzip

- **Katalog-Kern und Anfrage-Scoring sind getrennt:** Der RBF-Kernel (symmetrisch, positiv definit) trägt die RKHS-Interpretation; das Anfrage-Scoring ist asymmetrisch (Satisficing) und wird ausdrücklich nicht als Kernel deklariert.
- **PSD ist bewiesen und bewacht:** Gültigkeit der RKHS-Lesart ist an feste Scoring-Masken gebunden; ein Guard im Code lehnt paarweise verschiedene Masken ab, ein dokumentiertes Gegenbeispiel ($\min-\lambda = -1$) ist als Test gepinnt.
- **Kalibration statt Zauberformeln:** γ wird datengetrieben über die Median-Heuristik im jeweils aktiven Teilraum bestimmt — auf großen Katalogen über eine 500er-Stichprobe (Rang-Invarianz macht das exakt).
- **Inspiziert von RKHS-Regression** in der quantitativen Genetik (Gianola / de los Campos) — wir produktisieren denselben Formalismus für die Empfehlungsrichtung.

Referenz-Implementierung (TypeScript)

Port des produktiv erprobten SeedShuffle-Kernel-Kerns (Quelle per Commit gepinnt, semantisch diff-identisch). Läuft ohne Abhängigkeiten auf Node ≥ 22.18 — jede Aussage im Repo in fünf Minuten verifizierbar.

Engineering-Qualität

Zweiter SOLID-Rebuild in Python (Dependency Injection, reine Funktionen); CI prüft bei jedem Push: 59 Selbsttest-Checks, Demo-Lauf und ein **Eval-Gate mit 7 Qualitäts-Deckeln** — Qualitätsregression brechen den Build.

Nachvollziehbare Empfehlung statt Blackbox

AgriGen beantwortet die Anbauprofil-Frage direkt — mit einer Shortlist, die jeder Fachkraft erklärbar bleibt: welcher Anforderung jede Accession wie gut nachkommt, wo sie im Katalog-Perzentil steht und welche Kandidaten praktisch gleichwertig sind.

Für die Praxis

- **Landwirte & Beratung:** Anbau-Profil in natürlichen Begriffen („extreme Dürretoleranz, kurze Saison“) → qualifizierte Shortlist mit Erfüllungsgrad und Perzentil.
- **Genbanken:** Zugangswertigkeit wird sichtbar — C&E-Daten werden durch Suchbarkeit zum Aktiv, statt in Tabellen zu liegen.
- **Züchtung:** Parental-Screening über Trait-Profile statt Marker-für-Marker-Sichtung.

Für die Datenlage

- Der maskierte Kernel ist **von Grund auf für fehlende Daten gebaut:** nur gemeinsam beobachtete Merkmale fließen in die Distanz ein — genau die Struktur lückenhafter C&E-Daten.
- Ertragsnormalisierung pro Fruchtartgruppe vermeidet den klassischen Frisch-/Trockenmasse-Fehler.
- Anfragen mit wenigen Kriterien bleiben korrekt (Teilraum- γ) — keine Schätzungen aus Unbekanntem.

KI-Ehrlichkeit als Merkmal

Alle Qualitätswerte entstehen aus reproduzierbaren, label-freien Evaluierungen (Identitäts-Retrieval, Leave-One-Out-Stabilität, Rausch-Robustheit) und sind im Repository nachvollziehbar. Grenzen werden dokumentiert, nicht verschwiegen: exakte Duplikate sind prinzipiell ununterscheidbar und werden als Datenfehler abgelehnt; die erzielbare Genauigkeit wächst mit der Anfrage-Präzision (Quantisierungs-Leiter 0.44 → 1.00).

150

Accessionen im Demo-Katalog
(12 kuratiert + 138 generiert, Generator
committet)

12

quantitative Merkmale
je Accession

31

eval-getriebene Optimierungs-
Iterationen, jede mit Keep/Revert-
Entscheidung

Laufende Engine, gemessene Genauigkeit

AgriGen Matcher – kernel-basiertes Sorten-Matching (MVP)
RBF-Katalog-Kern · Hinge-Query-Scoring · Perzentil-Ranking

Katalog: 150 EURISCO-Accessionen × 12 Traits (normalisiert [0,1])
Katalog-Kern γ (Median-Heuristik, volle Maske) = 4.5957
Kernel-Matrix 150×150 (Diagnose): Rang 150/150 · Spur 150.000 · $\min-\lambda = 1.27e-3$ (PSD ✓)

SZENARIO A – Dürre & Hitze (Südeuropa)
Extreme Trockenheit, hohe Hitze, knappe Wasserressourcen, mäßige Salinität

Rang	Accession	Sorte	Query-Score (dim.)	Perzentil
1	EUR-116	Hordeum vulgare 'DryLand-116' (Ger...	1.000	besser als 94.7 % des Katalogs
2	EUR-103	Zea mays 'SaharaLine-103' (Portugal)	1.000	besser als 94.7 % des Katalogs
3	EUR-021	Sorghum bicolor 'DryLand-21' (Denmar...	1.000	besser als 94.7 % des Katalogs

SZENARIO C – Leguminosen-Screening / Low-Input
Maximale Stickstoff-Effizienz, hoher Ertragsfokus, moderate Wasserlage

Rang	Accession	Sorte	Query-Score (dim.)	Perzentil
1	EUR-066	Vicia faba 'SaharaLine-66' (Austria)	1.000	besser als 98.7 % des Katalogs
2	EUR-118	Glycine max 'DryLand-118' (Netherlan...	1.000	besser als 98.7 % des Katalogs
3	EUR-012	Vicia faba 'NitroFix-Plus' (Germany)	1.000	besser als 98.0 % des Katalogs
4	EUR-054	Vicia faba 'AquaSave-54' (Finland)	0.999	besser als 97.3 % des Katalogs

Echter Demo-Lauf (node mvp/demo.ts): Anfragen mit groben Stufen-Begriffen; Score 1.000 = Anforderungsprofil vollständig erfüllt; Ausgabe Rang, dimensionsloser Score, Katalog-Perzentil.

Gemessene Qualität (label-freie Evaluierung, alle Werte via node mvp/eval.ts reproduzierbar)

Kriterium	Messung	Ergebnis
Identity-Retrieval (Anfrage = Sortenprofil)	150 Accessionen, Vollmaske	1.0000 — jede Sorte findet sich selbst auf Rang 1
Teilraum-Identity	zufällige 4 von 12 Merkmalen	1.0000
Leave-One-Out-Stabilität	441 Katalog-Entfernungen	1.0000 Top-3-Jaccard
Bedauerns-Rate bei Anfrage-Rauschen	± 0.01 / ± 0.02 / ± 0.05 je Merkmal	0.000 / 0.000 / 0.001
Wizard-Genauigkeit (Stufen-Anfragen)	Vollmaske / 4 Merkmale	top-1 1.000 / top-3 0.989
Top-3-Treue bei Messrauschen in Sorten-Traits	± 0.02 / ± 0.05	0.849 / 0.740
γ -Kalibration bei 5.000 Accessionen	gesampelte Median-Heuristik	≈ 99 ms statt ≈ 20 s, Ranking unverändert

Technical Founder, der die Engine selbst baut und prüfen lässt

Sonny — Gründer & Entwickler

Baut die Matching-Engine eigenständig: Kernel-Mathematik, Datenmodell, Evaluierungs-Harness und Infrastruktur. Hintergrund in vektorbasierter Suche und produktionsreifen Empfehlungssystemen — der produktive Kernel-Kern von AgriGen ist ein Port aus einem live betriebenen Matching-System.

Arbeitsweise: eval-getrieben und adversarial geprüft

- Jede Algorithmus-Änderung lief durch messbare Hypothesen: 31 Iterationen, 17 übernommen, 6 datenbasiert verworfen — jede Entscheidung im öffentlichen Iterations-Log begründet.
- Die Mathematik wurde vor Fertigstellung von einem unabhängigen RKHS-Gutachten adversarial geprüft (inkl. vollständiger numerischer Replikation); alle Befunde sind eingearbeitet.
- Qualität ist automatisiert: CI prüft 59 Selbsttest-Checks, den Demo-Lauf und ein Eval-Gate mit sieben Qualitäts-Deckeln.

Adaptive AI Solutions

Einreichende Arbeitsplattform des Gründers für KI-Produktarbeit im Ruhrgebiet; Produktmarke für diese Einreichung: **AgriGen AI**.

Passung zum BRYCK-Umfeld

Pre-Seed-Phase, technische Umsetzungsstärke als Kernkompetenz; gesucht: Zugang zu Mentoring und Pilotkunden-Netzwerk (Beratung, Genbanken, Zucht).

Von 150 Muster-Datensätzen zu 2 Millionen echten Accessionen

Roadmap

Phase	Inhalt	Zeitfenster
M2 — Echte Daten	EURISCO-Passportdaten (IDs, Taxonomie, Herkunft) + Harmonisierung von C&E-Traits auf die 12-Merkmals-Matrix; der maskierte Kernel ist für die Lückenhaftigkeit bereits ausgelegt. Demo-Katalog heute transparent als modellierte Musterdaten gekennzeichnet (Generator committet).	Q4 2026
M3 — API & Web-Demo	FastAPI-Wrapper um den Rechenkern; Match-Wizard als Web-Oberfläche (Stufen-Präzision nach der gemessenen Quantisierungs-Leiter: Slider $\approx$ kontinuierlich = 1.000).	Q4 2026
M4 — Pilotkunden	Beratungsgesellschaften und Genbank-Zusammenhänge im Ruhrgebiet/NRW; Feedback-Schleife in die Trait-Harmonisierung.	Q1-Q2 2027

Skalierungspfad der Engine (gemessen, nicht behauptet)

- **Ranking skaliert linear** ($O(n \cdot d)$): 6,6 ms bei 5.000 Accessionen — für Millionen-Kataloge ohne Architekturwechsel.
- **γ -Kalibration über Stichprobe** statt aller Paare: konstant ≈ 100 ms unabhängig von n , Ranking nachweislich unverändert (Rang-Invarianz von γ).
- **Two-Stage-Retrieval** (grober Kandidaten-Filter $\rightarrow$ exaktes Re-Ranking) ist bei echten EURISCO-Größen der dokumentierte nächste Schritt — die HNSW-Erfahrung existiert in der Produktivumgebung, aus der der Kern portiert wurde.
- Datenhygiene eingebaut: Duplikat-Guard, Normalisierung pro Fruchtartgruppe, Trust-Boundary-Validierung aller Merkmalswerte.

Warum das jetzt trägt

Der Rechenkern steht auf messbarer Decke jedes falsifizierbaren Kriteriums — inklusive Robustheit gegen Anfrage-Ungenauigkeit und Messfehler in den Sortendaten. Damit ist das Risiko des Projekts nicht mehr die Mathematik, sondern ausschließlich die Daten-Erschließung. Genau diese Arbeit ist roadmap-bar, planbar und für einen Technical Founder ohne Agentur-abhängigkeit umsetzbar.